15 - 大幅提升 AI 的速度和稳定性

这篇文章分享几个提高 AI 生成代码的速度、稳定性、质量的方法。

1、切换大模型

之前用的是 DeepSeek 大模型，现在智谱推出了更快更强的 GLM-4.6 模型，建议大家替换一下，效果会好很多！

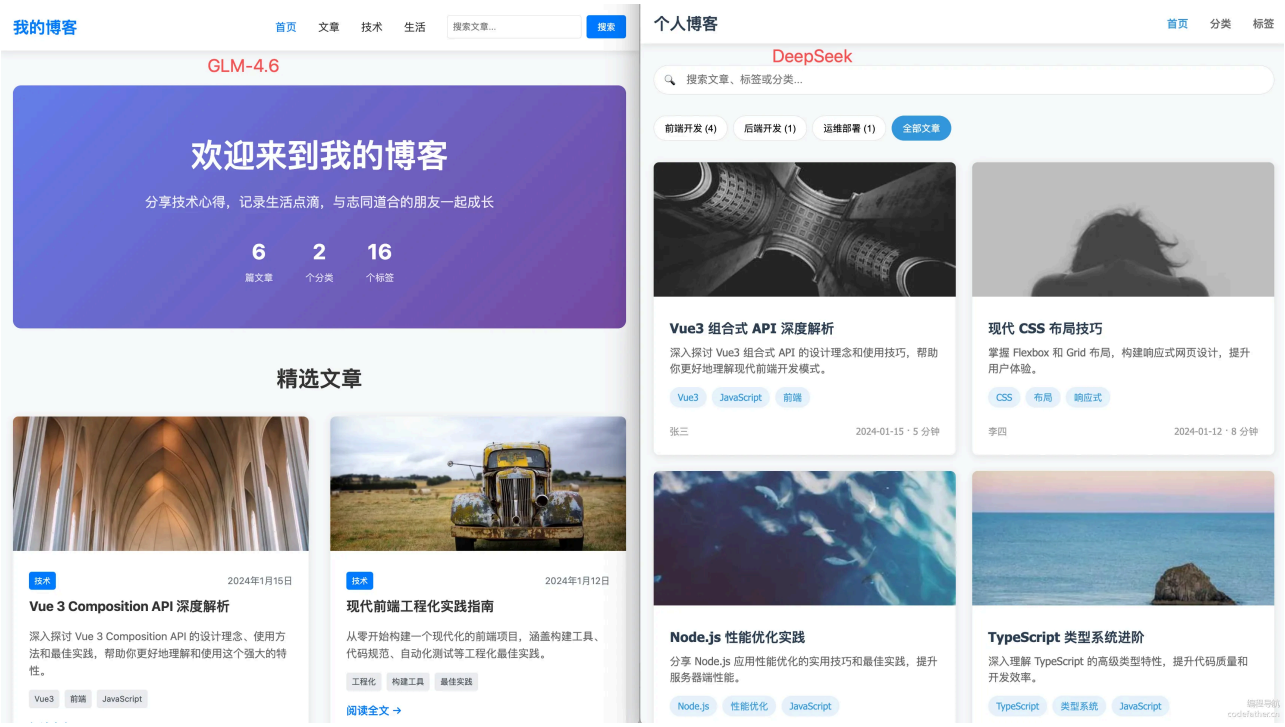

只需要修改 `application.yml` 中的配置即可：

▼

yaml
复制代码

```yaml
langchain4j:
  open-ai:
    streaming-chat-model:
      base-url: https://open.bigmodel.cn/api/paas/v4
      api-key: <Your API Key>
      model-name: glm-4.6
      max-tokens: 8192
    reasoning-streaming-chat-model:
      base-url: https://open.bigmodel.cn/api/paas/v4
      api-key: <Your API Key>
      model-name: glm-4.6
      max-tokens: 32768
      temperature: 0.1
```

注意，如果你要使用官方提供的 Coding Plan 的优惠套餐包，需要替换 `base-url` 为 `https://open.bigmodel.cn/api/coding/paas/v4`（中间多加了个 coding）。

如果你要生成更复杂的项目，max-tokens 可以调大点，GLM-4.6 有 200K 超长上下文窗口，写几十个页面都不成问题。

这里鱼皮是强烈推荐大家 **个人做项目时** 使用智谱的 Coding Plan 套餐包 的（点击链接可以优惠购买），直接包月，不按 tokens 数计费。但是如果是对外提供商业服务，还是更推荐直接使用 tokens，否则并发数量可能无法满足需求。

2、调大上下文窗口

如果 AI 有时无法正常完成任务、一直循环，建议调大 AiCodeGeneratorServiceFactory 的上下文窗口 maxMessages，防止 AI 断片儿：

▼

java
复制代码

```
MessageWindowChatMemory chatMemory = MessageWindowChatMemory
        .builder()
        .id(appId)
        .chatMemoryStore(redisChatMemoryStore)
        .maxMessages(50)
        .build();
```

3、设置超时时间

如果发现 AI 执行到一半，突然报错 "read timeout"，那可能是生成的代码太长，导致超时了。

可以修改配置类 ReasoningStreamingChatModelConfig 和 StreamingChatModelConfig，补充超时时间配置：

▼

java
复制代码

```
public class ReasoningStreamingChatModelConfig {

    // ... 省略前面的字段

    // 新增超时时间
    private Duration timeout;

    /**
     * 推理流式模型（用于 Vue 项目生成，带工具调用）
     */
    @Bean
    @Scope("prototype")
    public StreamingChatModel reasoningStreamingChatModelPrototype() {
        return OpenAiStreamingChatModel.builder()
                .apiKey(apiKey)
                .baseUrl(baseUrl)
                .modelName(modelName)
                .maxTokens(maxTokens)
                .temperature(temperature)
                .timeout(timeout) // 新增超时时间配置
                .logRequests(logRequests)
                .logResponses(logResponses)
                .build();
    }
}
```

然后在 `application.yml` 配置中添加超时时间配置即可：

▼

yaml
复制代码

```
langchain4j:
  open-ai:
    streaming-chat-model:
      base-url: https://open.bigmodel.cn/api/coding/paas/v4
      api-key: <Your API Key>
      model-name: glm-4.6
```

```
    max-tokens: 8192
    timeout: 300s
reasoning-streaming-chat-model:
    base-url: https://open.bigmodel.cn/api/coding/paas/v4
    api-key: <Your API Key>
    model-name: glm-4.6
    max-tokens: 32768
    temperature: 0.1
    timeout: 300s
```